第九章作业 参考答案

> **说明**：各题之后引用块中列出的力扣 / OpenJudge 编程题，只是与该题知识点对应的课外练习，仅供参考，不属于本次作业要求，无需提交。

1 日志文件的初始顺串

> 参考练习（不要求提交）：置换选择的核心是维护一个最小堆并不断补入新记录，对应 OpenJudge 31418 筛选法建最小堆的交换次数、力扣 703. 数据流中的第 K 大元素。
>
> **31418: 筛选法建最小堆的交换次数**
>
> http://cs101.openjudge.cn/practice/31418/
>
> **E703. 数据流中的第 K 大元素**
>
> https://leetcode.cn/problems/kth-largest-element-in-a-stream/

(1) 置换选择过程

开始时工作区中有 `13`，`23`，`5`，`8`，`18`，建最小堆后堆顶为 5。每次只从当前顺串的可用记录中取最小值；冻结记录仍占工作区，但不参加当前顺串的选择。下表中可用记录按升序列出，“无” 表示输入已读完。

顺串	本次输出	新读入	对新记录的处理	输出并补入后的可用记录	冻结记录
1	5	11	11 ⩾ 5，可用	8, 11, 13, 18, 23	—
1	8	29	29 ⩾ 8，可用	11, 13, 18, 23, 29	—
1	11	7	7 < 11，冻结	13, 18, 23, 29	7
1	13	14	14 ⩾ 13，可用	14, 18, 23, 29	7
1	14	10	10 < 14，冻结	18, 23, 29	7, 10
1	18	16	16 < 18，冻结	23, 29	7, 10, 16
1	23	19	19 < 23，冻结	29	7, 10, 16, 19
1	29	24	24 < 29，冻结	—	7, 10, 16, 19, 24

顺串	本次输出	新读入	对新记录的处理	输出并补入后的可用记录	冻结记录
2	7	17	17 ⩾ 7，可用	10, 16, 17, 19, 24	—
2	10	9	9 < 10，冻结	16, 17, 19, 24	9
2	16	无	不再补入	17, 19, 24	9
2	17	无	不再补入	19, 24	9
2	19	无	不再补入	24	9
2	24	无	不再补入	—	9
3	9	无	不再补入	—	—

每个顺串结束后才解除冻结记录的标记。最终得到：

```
顺串 1: 5, 8, 11, 13, 14, 18, 23, 29
顺串 2: 7, 10, 16, 17, 19, 24
顺串 3: 9
```

三段长度分别为 8、6、1，合计 15 条，与输入一致。第一段的长度 8 超过了工作区容量 5：记录输出后腾出的位置可以继续接收适合本段的新记录，这正是置换选择比 “装满、排序、写出” 的简单方法产生更长顺串的原因。

(2) 正确性说明

每段非降序。设刚输出的值为x。它是当时所有可用记录中的最小值，因此工作区中剩下的可用记录都不小于x；新读入的记录也只有在不小于x 时才被允许参加本段。于是下一次输出的值不小于x，归纳可得整段非降序。

不重复、不遗漏。每条输入记录只读入一次，读入后处于 “可用” 或 “冻结” 两种状态之一，直到被输出并移出工作区。冻结只是推迟输出，并不丢弃记录；一段结束时冻结记录全部转为可用。输入耗尽后算法继续处理工作区中的全部剩余记录，直到工作区为空。因此每条记录恰好输出一次。

(3) 初始顺串数的上下界

最少为 1 个。输入已经升序时，每条新记录都不小于刚输出的值，始终可以加入当前顺串，2026 条记录形成一段。

最多为 254 个。若输入严格降序，每条新读入的记录都小于刚输出的值，只能被冻结。于是除末段外，每段恰好输出工作区容量对应的 8 条记录：

$$\left\lceil \frac{2026}{8} \right\rceil = 254,$$

其中前 253 段各 8 条，最后一段 2 条。

这也是上界：输入尚未耗尽时，每输出一条就补入一条，工作区始终满载；一段结束时留给下一段的记录全部是被冻结的记录。若某一段开始时工作区不足 8 条，说明输入已耗尽，剩余记录解除冻结后可在同一段内全部输出，所以这只能是最后一段。因此每个非末段至少输出 8 条，顺

串数不超过$\lceil 2026/8 \rceil = 254$。

2 八路归并中的败者树

> 参考练习（不要求提交）：多路归并对应力扣 23. 合并 K 个升序链表（用最小堆或败者树每次取 K 路中的最小者）。
>
> **H23. 合并 K 个升序链表**
>
> https://leetcode.cn/problems/merge-k-sorted-lists/

(1) 初始建树

自底向上比赛，每场比赛的胜者继续向上，败者的顺串编号留在该内部结点：

结点	比较双方	胜者	存入的败者编号
L[4]	R1:18 与 R2:7	R2:7	1
L[5]	R3:25 与 R4:11	R4:11	3
L[6]	R5:16 与 R6:4	R6:4	5
L[7]	R7:30 与 R8:9	R8:9	7
L[2]	R2:7 与 R4:11	R2:7	4
L[3]	R6:4 与 R8:9	R6:4	8
L[1]	R2:7 与 R6:4	R6:4	2

总冠军是 R6，故 `L[0] = 6`。初始数组为：

```
下标：  0  1  2  3  4  5  6  7
L：     6  2  4  8  1  3  5  7
```

(2) 前三次输出与重构

第一次：输出 R6 的 4，补入 15。沿 R6 到根依次经过 `L[6]`、`L[3]`、`L[1]`，每到一个结点就与结点中记录的败者比赛，胜者继续向上、败者留下：

比较位置	比较双方	胜者继续向上	新败者编号
L[6]	R6:15 与 R5:16	R6:15	5
L[3]	R6:15 与 R8:9	R8:9	6
L[1]	R8:9 与 R2:7	R2:7	8

新冠军为 R2 的 7。

第二次：输出 R2 的 7，补入 19。经过 `L[4]`、`L[2]`、`L[1]`：

比较位置	比较双方	胜者继续向上	新败者编号
L[4]	R2:19 与 R1:18	R1:18	2
L[2]	R1:18 与 R4:11	R4:11	1
L[1]	R4:11 与 R8:9	R8:9	4

新冠军为 R8 的 9。

第三次：输出 R8 的 9，补入 24。经过 `L[7]`、`L[3]`、`L[1]`：

比较位置	比较双方	胜者继续向上	新败者编号
L[7]	R8:24 与 R7:30	R8:24	7
L[3]	R8:24 与 R6:15	R6:15	8
L[1]	R6:15 与 R4:11	R4:11	6

前三条输出为 4，7，9，新冠军为 R4 的 11。各阶段数组汇总如下：

阶段	L[0]	L[1]	L[2]	L[3]	L[4]	L[5]	L[6]	L[7]
初始	6	2	4	8	1	3	5	7
输出 4，补入 15	2	8	4	6	1	3	5	7
输出 7，补入 19	8	4	1	6	2	3	5	7
输出 9，补入 24	4	6	1	8	2	3	5	7

(3) 比较次数

初始自底向上建树，每个内部结点进行一次比较，共$8-1=7$次。

每次替换冠军时，只有从该叶子到根的路径上的比赛结果可能改变，经过 3 个内部结点、每层一次比较，共$\log_2 8=3$次；其他子树的比赛结果可以直接沿用。

(4) 与逐路扫描的区别

每次扫描 8 个当前记录求最小值需要 7 次比较；败者树在建树之后每次只需 3 次重赛。一般地，k 路归并逐路扫描每输出一条记录要$k-1$次比较，败者树只要$\lceil \log_2 k \rceil$次。败者树减少的是**从各路当前记录中选出最小值的关键字比较工作**，即内存中的 CPU 开销。

不能据此断言磁盘读写也按相同比例减少。各路的当前记录已经在输入缓冲区中，比较在内存中完成；磁盘 I/O 只在输入缓冲区读空需要补充下一块、输出缓冲区写满需要写出时发生。在相同的缓冲区安排和归并方案下，无论用什么方法选最小值，读入和写出的块数都相同。败者树的真正意义是让k可以取得更大而不增加比较量，从而减少归并趟数、间接减少 I/O（见第 4 题）。

3 怎样归并才能少读写磁盘

> 参考练习（不要求提交）：最佳归并树就是以顺串长度为权的哈夫曼树，对应 OpenJudge 18164 剪绳子（二叉情形）；力扣 1167. 连接棒材的最低费用为同类会员题。
>
> **18164: 剪绳子**
>
> http://cs101.openjudge.cn/practice/18164/

(1) 归并路数与最少趟数

4 个块缓冲区中必须留 1 个作输出缓冲区，最多剩 3 个输入缓冲区，因此最多进行 **3 路归并**。

一趟最多把 8 个顺串归并为$\lceil 8/3 \rceil = 3$个，再一趟归并为 1 个：

$$8 \longrightarrow 3 \longrightarrow 1,$$

所以按整趟分组归并至少需要 **2 趟**。

(2) 最佳归并顺序

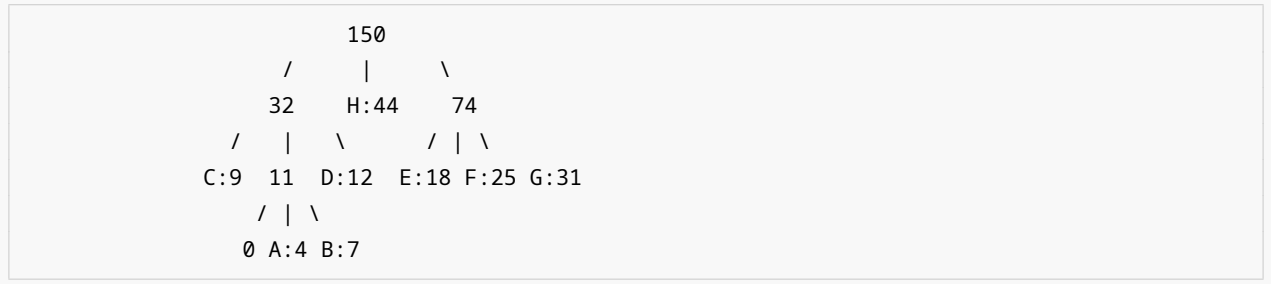
一个块位于归并树的第几层，就要参与几次归并（读一次、写一次）。因此应尽量让长顺串少参与归并、短顺串承担较多层数，这正是以顺串长度为权的哈夫曼树问题，每个内部结点最多有 3 个孩子。

为什么可以只考虑“补一个虚拟顺串的满三叉树”。若归并树中有两个二叉内部结点，记较深的为u、另一个为v，把u 的一棵子树移作v 的第三棵子树，再删除只剩一个孩子的u，由它剩下的孩子接替它的位置：被移动的子树不会变深，接替u 的子树还会变浅，其余叶子深度不变，总代价不增而二叉内部结点少了两个。反复调整后至多剩一个二叉内部结点。内部结点都有 3 个孩子的满三叉树叶子数满足$(\text{叶子数}-1)\bmod 2=0$，本题 8 个叶子是偶数，所以必定剩一个二叉结点；给它补一个权为 0 的叶子，就得到代价相同、9 个叶子的满三叉树。虚拟顺串不含记录、不产生读写，与它合并等价于该次只归并两个实际顺串。

三**叉哈夫曼过程**。加入虚拟顺串 0 后，每次选当前最短的三个顺串归并：

步骤	参与归并的顺串长度	结果及长度	归并后尚待处理的长度
1	0, 4, 7	X = 11	9, 11, 12, 18, 25, 31, 44
2	9, 11, 12	Y = 32	18, 25, 31, 32, 44
3	18, 25, 31	Z = 74	32, 44, 74
4	32, 44, 74	最终顺串 = 150	150

对应的实际操作：先归并 A、B 得 X；再归并 C、X、D 得 Y；另归并 E、F、G 得 Z；最后归并 Y、H、Z。归并树如下：



贪心的正确性：在任一最优树中，若较长顺串比较短顺串更深，交换两者不会增加总代价，所以总可以把最小的三个权安排为最深处的一组兄弟叶子；把它们合成一个权为三者之和的新叶子后，剩下的仍是同类问题，重复即可。

(3) 最优方案的磁盘读写

每次归并读入的块数等于结果长度，并把同样多的块写回：

$$\text{总读块次数}=11+32+74+150=267,\qquad \text{总写块次数}=267,$$

$$\text{总块 I/O}=267+267=534.$$

按每个原始顺串在树中的深度核对读块次数：$3\times(4+7)+2\times(9+12+18+25+31)+1\times 44=33+190+44=267$。

(4) 与固定分组方案比较

固定方案第一趟产生三个顺串，长度分别为

$$4+7+9=20,\qquad 12+18+25=55,\qquad 31+44=75.$$

第一趟读 150 块、写 150 块，第二趟再读 150 块、写 150 块：

$$\text{总读}=300,\qquad \text{总写}=300,\qquad \text{总块 I/O}=600,$$

比最优方案多$600-534=66$ 次块 I/O。

固定方案让每一块都经过两层归并。最优方案中 A、B 的 11 块多经过一层，但 H 的 44 块少经过一层，其余仍是两层，读块量减少$44-11=33$，写块量同样减少 33，合计少 66 次。“趟数相同” 只是说每块的归并次数相等，而总读写量是各块归并次数的**加权和**，权就是顺串长度；让长顺串晚些参与归并，才能真正减少读写。

4 归并路数、趟数与内部比较次数

(1) 3 趟内完成所需的最低路数

$m=80$ 个初始顺串用k 路归并需要$\lceil \log_k 80\rceil$ 趟。要求 3 趟内完成，即$k^3\ge 80$:

$$4^3=64<80\le 125=5^3,$$

所以k 至少取 **5**。

(2) 文件数限制下的趟数与路数

k 路归并同时打开k 个输入文件和 1 个输出文件，$k+1\le 15$ 给出$k\le 14$。14 路归并需要

$$\lceil \log_{14} 80\rceil=2\quad (14<80\le 196=14^2)$$

趟，所以至少需要 **2 趟**。若限定 2 趟，需要$k^2\ge 80$，$8^2=64<80\le 81=9^2$，可取的最低路数为 **9**。

(3) 两种选最小值方法的比较总次数

每趟归并要输出全部n 条记录，每输出一条记录就要在k 路当前记录中选一次最小值（最后一条无需比较）。共$\lceil \log_k m\rceil$ 趟，于是:

- **逐路扫描**：每次选最小值比较$k-1$ 次，总比较次数

$$\lceil \log_k m\rceil\cdot(k-1)\cdot(n-1)=\left\lceil\frac{\log_2 m}{\log_2 k}\right\rceil(k-1)(n-1).$$

  m 固定时$(k-1)/\log_2 k$ 随k 增大而增大，增大路数虽然减少了趟数，内部比较量反而上升。
- **败者树**：每次选最小值只沿一条叶到根的路径比较$\lceil \log_2 k\rceil$ 次，总比较次数

$$\lceil \log_k m\rceil\cdot\lceil \log_2 k\rceil\cdot(n-1)\approx\lceil \log_2 m\rceil(n-1),$$

与k基本无关(k为 2 的幂时恰好相等;本题$m=80$、$k=9$时为$2\times 4\times(n-1)=8(n-1)$,与$\lceil \log_2 80\rceil = 7$相差不大)。每趟建树的$k-1$次比较可忽略。

因此采用败者树后,增大k几乎不增加内部比较量,却能减少趟数,而每趟都要把全部记录读写一遍,所以总 I/O 随趟数减少。此时k的大小主要受**内存中可用的输入缓冲区数量**限制:每路至少要一个输入缓冲区,再加输出缓冲区;缓冲区过多过小会使每次 I/O 读写的块变小,寻道开销反而上升。操作系统同时打开文件数的限制也是约束之一(如第 (2) 问)。

> 核对说明:第 1、2、3 题取自本次作业的原始题目,原答案经脚本逐题复核无误(置换选择顺串划分、败者树各阶段数组、最佳归并 534 与固定方案 600);此处补充了第 2 题第 (4) 问关于 I/O 发生时机的说明。第 4 题为依据教材 9.3.3 节及本章习题 3 新增。